2.1

제출일 : **2025-11-05**

빅데이터 응용프로그래밍

데이터 기반 한국영화 성공 공식 분석

인공지능소프트웨어 **[QB]**
20232678 조은성

주제 선정 이유 및 배경

분석 필요성

- "오징어게임" K-드라마가 글로벌 1위를 차지했지만, 같은 시기 한국영화 시장 점유율은 42%로 역대 최저 수준 기록

- 2024년 영화 관객 수는 1억 5천만 명으로 2019년 대비 32% 급감하며 팬데믹 이후에도 회복 실패

- K-드라마는 전 세계 90개국 TOP 10 진입하는데 한국영화의 90%는 해외 진출 실패, 데이터기반 설명 부재

- OTT 플랫폼 확산으로 관객 소비 패턴이 급변했으나 극장 영화의 차별화 전략은 여전히 과거 방식에 의존

산업적 필요성

- 2020~2024년 전국 극장 20% 폐쇄로 상영관 인프라 급속 붕괴 중

- 흥행 불확실성 증가로 투자 위축되며 중소 제작사 연쇄 도산 발생

- 극장 폐쇄 → 영화 제작 감소 → 다양성 감소 → 관객 이탈 → 추가 폐쇄의 악순환 구조 고착화

극장 영화의 중요성

- 영화관은 사람들이 함께 감동하는 집단적 문화 경험을 제공하는 공공 문화 공간

- 대형 스크린과 음향 시스템은 감독이 의도한 예술적 경험을 온전히 전달하는 방법

- OTT 알고리즘은 안전한 콘텐츠만 선호하지만 극장은 독립영화와 예술영화의 생존 공간 제공

주제 선정 이유 및 배경

기존 연구와 차별성

- 팬데믹 이전과 이후의 특징을 비교분석

- 기존 연구는 국내 시장만 분석했으나 본 연구는 국내 흥행과 해외 성공의 차이를 비교 분석

- 2025년 최신 데이터 활용으로 실시간 트렌드 반영 가능하며 즉시 적용 가능한 전략 도출

해결하고자 하는 문제

- 국내 흥행 영화의 공통 특징은?

- 해외에서 성공한 한국영화의 차별화 요소는?

- 장르, 개봉 시기 등 흥행에 가장 큰 영향 요인은?

- 국내 성공 공식과 해외 성공 공식의 차이점은?

기대효과

- 데이터 패턴 기반 흥행 요인 도출

- 국내 및 해외 시장별 차별화 전략 제시

- 영화 제작사의 기획 단계 의사결정 지원

- 극장과 OTT의 상생 구조 정착으로 예술적 실험과 상업적 성공이 공존하는 건강한 생태계 구축

데이터 수집 계획

영화진흥위원회 KOBIS

- 2019~2025년 박스오피스
- 영화 상세 정보 수집
- KOBIS Open API 활용

네이버 영화

- 관객 평점 및 기본 정보
- 영화당 리뷰 100개 샘플링
- 크롤링

Kaggle 데이터셋

- Korean Movies Dataset
- 해외 박스오피스 수익 정보
- CSV 다운로드

수집 방법 및 주의사항

- Open API 우선 활용
- 크롤링 시 robots.txt 확인
- 개인정보 수집 금지

데이터 전처리 계획

1. **결측치 및 오류 데이터 처리**
   - 결측값 처리 : 중앙값 대체 또는 분석에서 제외
   - 중복 데이터 제거 : 재개봉 영화 데이터 통합
   - 이상치 처리 : 비정상적 관객 수, 극단적 평점 제거

2. **데이터 통합 및 정규화**
   - 데이터 병합 : KOBIS, 네이버, Kaggle 데이터 통합
   - 데이터 형식 통일 : YYYY-MM-DD 형식으로 표준화
   - 장르 카테고리 통일 : 드라마, 액션, 코미디 등 통일

3. **변수 생성**
   - 흥행 성공 여부 변수 : 손익 분기점이 밝혀지지 않은 영화가 존재, 관객 수 300만 명 기준 (성공/실패)
   - 개봉 시기 변수 : 봄(3-5월), 여름(6-8월), 가을(9-11월), 겨울(12-2월)
   - 해외 성공 여부 변수 : IMDb 등재 및 평점 7.0 이상

분석 방법

▶ 탐색적 데이터 분석 (EDA)

- 장르별, 연도별, 시즌별 관객 수 분포 분석
- 국내 흥행작 vs 해외 성공작 특징 비교
- 박스오피스 수익 분포 분석

▶ 통계 분석

- 기술통계량 산출 : 평균, 중앙값, 표준편차, 사분위수
- T-test 분석 : 흥행작 vs 비 흥행작 그룹 간 차이 검증
- 단순 선형 회귀분석 : 평점, 개봉 시기, 장르 등 주요 변수 분석

▶ 머신러닝 분석

- Random Forest 분류 모델 : 흥행 성공 또는 실패 예측
- Feature Importance 분석 : 핵심 흥행 요인 도출

분석 도구 및 기술 스택

- **Python 라이브러리**
  - Requests : KOBIS API 호출 및 HTTP 통신을 처리
  - BeautifulSoup4, Selenium : 네이버 영화 웹페이지의 평점과 리뷰 데이터 크롤링
  - Pandas : CSV 파일 처리
  - Numpy : 수치 연산과 통계 계산
  - Scikit-learn : Random Forest 모델 구축, 데이터 분할, 모델 평가, Feature Importance 분석
  - KoNLPy : 한국어 리뷰 텍스트 분석
  - Matplotlib, seaborn : 히스토그램, 산점도, 선 그래프 등 데이터 시각화
  - Scipy : T-test, 상관계수 계산 등 통계 검정을 수행

- **개발 환경**
  - VScode
  - 로컬 아나콘다 가상 환경
  - Github를 통한 버전관리

기대 결과 및 활용 방안

정량적 결과

- 흥행 영향 요인 Top 3~5 도출
- 장르별 평균 관객 수 및 성공률 비교
- 시즌별 최적 개봉 전략 제시
  액션 영화는 여름 개봉 시 관객 수 20% 증가
- 흥행 예측 모델 구축

정성적 결과

- 국내 흥행작의 공통 패턴 발견
- 흥행 실패작의 공통 요인 파악
- 관객 리뷰 주요 키워드 분석
- 장르별 선호 요소 도출
- 국내 vs 해외 성공 요인 비교

실제 활용 방안

- 영화 제작사
  - 기획 단계 평가
  - 최적 개봉 시기
  - 타겟 시장 전략
- 투자 및 마케팅
  - 투자 의사결정
  - 타겟 관객층 분석
  - 마케팅 전략 수립

프로젝트 일정

1주차: KOBIS API 연동, 네이버 영화 크롤링, Kaggle 데이터셋 다운로드

2주차: 데이터 통합 및 전처리, 결측치 처리, 파생변수 생성

3주차: EDA 수행, 기술통계량 산출, 시각화, 상관관계 분석

4주차: Random Forest 모델 구축, 학습 및 평가, Feature Importance 분석

5주차: 최종 보고서 작성, PPT 제작

참고문헌 및 출처

데이터 출처

- 영화진흥위원회 KOBIS
https://www.kobis.or.kr/

- 네이버 영화
https://movie.naver.com/

- Kaggle Datasets
https://www.kaggle.com/datasets

- IMDb
https://www.imdb.com/

산업 보고서

- 영화진흥위원회 (2024)
2023년 한국영화산업 결산

- 한국콘텐츠진흥원
콘텐츠산업 통계

- 영화진흥위원회 (2024)
영화산업 동향 보고서

- 영화진흥위원회 통계정보

학술 자료

- 김진웅, 서영덕 (2019)
영화 장르별 소비자 고려요인 및 흥행요인 분석

- 최성희 (2020)
영화의 개봉일 흥행성과가 영화의 최종 흥행에 미치는 영향

- 김현건 , 우지환 (2025)
AI와 ML 기법을 활용한 영화의 흥행 예측 연구

기술 문서

- Python pandas
https://pandas.pydata.org/docs/

- Scikit-learn
https://scikit-learn.org/

- KoNLPy
https://konlpy.org/

- BeautifulSoup4
https://www.crummy.com/