경영정보학연구
제27권 제1호, 2025년 2월 http://dx.doi.org/10.14329/isr.2025.27.1.179

AI와 Machine Learning 기법을 활용한 영화의 흥행 예측 연구: 영화 개봉 전 상호 데이터를 중심으로

Predicting Box Office Success Using AI and Machine Learning: A Pre-Release Data-Driven Approach

김 현 건 (Hyeon-Geon Kim) CJ올리브네트웍스 AI연구소 연구원, Data Scientist
우 지 환 (Jihwan Woo) CJ올리브네트웍스 AI연구소 부장/KAIST 경영대학 겸직교수, 교신저자

요 약

본 연구는 영화 개봉 전 활용 가능한 정적 데이터를 기반으로 AI 및 기계 학습(Machine Learning, ML) 기법을 활용한 영화 흥행 예측 모델을 제안하고, 이를 기존 베이스라인 모델과 비교하여 성능을 평가하였다. 2013년부터 2024년까지 수집된 KOBIS 데이터를 활용하여 배우, 감독, 배급사, 장르별 기술 통계와 상호작용 파생변수를 생성하였으며, RFECV(Recursive Feature Elimination with Cross-Validation)를 통해 주요 변수를 선별하였다. 또한, AutoML 기법을 적용하여 데이터셋에 최적화된 모델을 학습하고, 네이버 검색어 트렌드 데이터를 추가적으로 반영하여 예측 성능을 향상시켰다. 실험 결과, 최종 제안모델은 베이스라인 모델 및 기존 연구모델을 뛰어넘는 성능을 보였으며, F1-Macro 및 AHPR-Bingo를 활용한 평가 척도에서 높은 정확도를 기록하였다. 특히, 상호작용 파생변수는 모델 성능 개선에 기여하는 주요 변수로 나타났으며, 정적 데이터를 활용한 예측 모델이 영화 산업 내 의사결정 과정에서 유의미한 도구로 작용할 수 있음을 입증하였다. 본 연구는 정적 데이터만을 활용한 영화 흥행 예측 모델을 제안함으로써 학술적 및 실무적 기여를 제공한다. 연구 결과는 영화 제작사와 배급사가 개봉 전 전략적 의사결정을 지원하는 데 유용한 프레임워크를 제공하며, 향후 연구는 동적 데이터를 포함한 확장된 모델 개발 및 다양한 데이터셋 적용을 통해 본 연구를 보완할 수 있을 것으로 기대된다.

키워드 : 영화 흥행 예측, Box Office Prediction, Automated Machine Learning, Interaction Data, Recursive Feature Elimination with Cross Validation

Ⅰ. 서 론

영화 산업은 전 세계적으로 문화적, 경제적 가치를 창출하는 주요 산업 중 하나로 자리 잡았다. 2024년 기준, 글로벌 영화 시장의 규모는 약 390억 달러에 달했으며, 시장 규모는 2027년 약 500억 달러로 성장이 예측된다(오승은, 2024). OTT(Over-The-Top) 플랫폼의 확산과 같은 영화에 대한 새로

운 소비 형태가 더해지면서 시장규모는 더욱 지속적인 성장세가 기대된다. 한국의 영화 산업 역시 최근 K-Culture에 대한 관심도가 높아지면서, 글로벌 시장에서 독보적인 위치를 점유하고 있으며, 약 2조 원 이상의 시장 규모와 함께, 문화적 영향력과 상업적 가치를 동시에 창출하고 있다(영화진흥위원회, 2024). 이러한 거대한 시장 규모는 영화 제작 및 배급 과정에서의 전략적 의사결정이 영화의 성공 여부를 좌우하는 핵심 요인이 되고 있다는 것을 보여준다.

영화 흥행 예측은 영화 산업에서 전략적 의사결정을 지원하는 핵심 요소로 자리 잡고 있다. 영화 제작은 막대한 자본이 투입되는 고위험 고수익 사업으로, 흥행 여부에 따라 투자 수익률이 극명하게 갈리는 특징을 가지고 있다. 박스 오피스 성과는 영화의 상업적 성공을 가늠하는 중요한 지표로, 이를 정확히 예측하는 것은 마케팅 전략 수립, 배급 일정 조정, 투자 우선순위 결정 등 제작과 배급 과정 전반에 걸쳐 중요한 영향을 미친다 (Ahmed *et al.*, 2020; Liao *et al.*, 2022). 최근 영화 시장의 경쟁이 치열해지면서, 소비자 선호도를 정확히 반영하고 변화하는 시장 트렌드를 파악하는 예측의 중요성은 더욱 부각되고 있다. 특히, OTT 플랫폼과 같은 새로운 유통 채널이 등장하며 영화 흥행의 정의와 평가 기준이 변화하고 있어, 데이터 기반의 정교한 예측 모델이 필수적인 도구로 자리 잡고 있다. 이를 통해 영화 제작사와 배급사는 한정된 자원을 효율적으로 배분하고, 관객의 기대에 부응하는 콘텐츠를 제공할 수 있는 경쟁력을 확보할 수 있다.

특히, 영화 흥행 예측은 학술적, 실무적으로 모두 중요한 주제로 부각되고 있다. 학술적 관점에서 영화 흥행 예측은 데이터 기반 의사결정과 AI 및 기계 학습(Machine Learning, ML) 기술의 응용 가능성을 탐구하는 데 있어 중요한 연구 분야를 형성한다. 영화의 흥행 성과는 단순한 상업적 지표를 넘어 소비자 심리, 사회적 트렌드, 그리고 기술적 환경 변화와 밀접하게 연관되어 있다. 이러한 예측 문제는 영화 제작비, 장르, 감독 및 배우와 같은 정형 데이터뿐만 아니라, 소셜 미디어에서의 언급량, 리뷰 감정, 경쟁작 개봉 시기와 같은 비정형 데이터를 통합적으로 고려해야 하는 복잡한 특성을 지닌다.

기존의 통계 기반 예측 방법 (김병도, 2002; 김병선, 2009)은 이와 같은 복잡성과 다차원성을 효과적으로 반영하지 못한다는 한계를 지닌다. 예를 들어, 전통적 모델은 주로 선형 회귀와 같은 기법을 사용하여 정형 데이터에만 의존하며, 소비자 감정 분석이나 트렌드 변화와 같은 요소를 충분히 고려하지 못한다. 반면, AI와 ML 기반 모델은 대규모 데이터셋에서 숨겨진 패턴을 학습하고, 비정형 데이터와 정형 데이터를 결합하여 높은 예측 정확도를 제공할 수 있다. 이처럼 AI와 ML의 도입은 영화 흥행 예측 문제를 더욱 정교하고 실효성 있는 방법으로 접근할 수 있는 가능성을 열어준다.

본 연구는 기존 연구(Ahmed *et al.*, 2020; Liao *et al.*, 2022)들에서 주로 활용된 앙상블 모델과 정적 - 동적 데이터 결합 방식의 한계를 넘어서는 새로운 접근을 제안한다. AutoML을 활용하여 데이터셋 특성에 최적화된 모델을 자동으로 선정하고, RFECV를 통해 상호작용 파생변수를 효과적으로 선별하였다는 점에서 기존 연구(Leem *et al.*, 2023; Misra and Arun, 2019)가 가진 문제점을 해결하였다. 이를 통해 정적 데이터만으로도 높은 예측 성능을 달성하며, 개봉 전 단계에서 실질적으로 활용 가능한 데이터 분석 프레임워크를 제시한다. “배급사-장르별 평균 관객수 조합”과 같은 변수는 기존 연구에서 다루지 않은 새로운 통찰을 제공하며, 실무적 의사결정에 기여할 수 있음을 입증하였다.

실무적 관점에서도 AI와 ML 기반 예측은 영화 제작사와 배급사에 실질적인 가치를 제공한다. 영화 제작은 대규모 예산이 투입되는 고위험 투자이기 때문에, 박스 오피스 수익을 정확히 예측하는 것은 제작비와 마케팅 비용 배분, 배급 전략 설계 등에서 매우 중요한 역할을 한다. AI 기반 예측

모델은 데이터에 기반한 객관적 의사결정을 가능하게 하며, 예상되는 수익성을 바탕으로 마케팅과 배급 전략을 최적화할 수 있도록 돕는다. 예를 들어, 특정 배우나 장르의 흥행 가능성을 사전에 분석하여 투자 우선순위를 정하거나, 소셜 미디어에서의 실시간 소비자 반응을 활용해 마케팅 캠페인을 동적으로 조정할 수 있다.

AI와 ML의 또 다른 장점은 비정형 데이터의 활용 가능성이다. 소셜 미디어 리뷰, 트렌드 키워드, 실시간 소비자 감정을 분석함으로써 전통적 데이터로는 알 수 없는 시장의 숨은 니즈를 발견할 수 있다. 예를 들어, 최근 일부 영화 제작사는 AI를 활용하여 특정 장르나 주제가 특정 시장에서 인기가 높을 가능성을 사전에 예측해 배급 전략을 설계하고 있다.

따라서 본 연구는 AI와 ML 기술을 활용하여 영화 흥행 성과를 예측하는 모델을 개발하고, 이를 기존 통계적 방법론과 비교하여 효용성과 확장 가능성을 평가하는 데 목적을 둔다. 또한, 영화 산업 내 데이터 중심 의사결정의 가치를 탐구함으로써, 급변하는 시장 환경에서도 효과적이고 신뢰할 수 있는 예측 방법론을 제안하고자 한다.

Ⅱ. 문헌연구

영화 흥행 예측에 대한 선행연구에서는 학습에 활용할 수 있는 데이터를 크게 정적 데이터(Static Data)와 동적 데이터(Dynamic Data)로 구분한다(Chang, 2017; Song, 2018). 정적 데이터는 배우, 감독과 같이 정량적인 변화가 없는 고정된 변수들이며 영화 개봉 이후 유동적으로 변동될 수 있는 영화 평점, 영화 기사 수, 소셜 네트워크의 반응 등을 영화 개봉 이후 변동적인 데이터라고 지칭한다(Chang, 2017). 머신러닝과 딥러닝에 기반해 해당 데이터를 활용하여 다양한 영화 흥행 예측 방법론들이 제안되었으며 본 연구에서는 이러한 방법론들을 크게 2가지로 분류하여 검토하였다. 또한 RFECV를 활용한 변수 선택법과 AutoML을 활용하여 머신러닝 모델을 구축한 방안에 대해서도 검토하였다.

2.1 단일 모델 및 변수 선택 기반 예측 방법론

흥행 예측을 위한 선행연구에서 머신러닝/딥러닝 기반 모델 연구와 여러 학습 변수 중 유의미한 변수를 추출하여 모델 학습에 반영시키는 변수 선택 기반의 연구들이 수행되었다.

Chang(2017)은 정적변수와 영화 개봉 일주일전 동적변수를 통해 적절한 변수를 조합하여 나이브 베이지안 모델과 인공신경망을 통해 영화 흥행을 예측했다. Song(2018)은 MLP, SVM, Random Forest 모델을 비롯한 총 5가지 머신러닝/딥러닝 모델을 통해 개봉 당일, 1주일 누적, 2주일 누적, 3주일 누적 관객수를 예측하는 형식으로 영화 흥행을 예측했다. Kwon *et al.*(2017)은 흥행 예측력을 높이기 위하여 회귀분석을 통해 유의미한 변인들을 추출하고 인공신경망과 의사결정나무 모델을 통해 학습한 모델을 제안했다. Byun *et al.*(2020)은 Random Forest 모델을 통해 주요 변수를 선별하고 잔차 네트워크(Residual Network) 모델을 제안했다. Wang *et al.*(2022)은 Random Forest 모델을 통해 주요 변수 71개를 추출하고 수익을 예측할 수 있는 점추정 인공신경망 모델을 제안했다. Song(2022)은 영화 흥행에 영향이 있는 독립변수들을 찾아내기 위해서 AHP 기법을 통해 영화전문가들에 대한 설문조사를 실시하고 중요 요인을 추출하였으며 전문가 서베이 정보와 빅데이터를 모두 반영한 모델을 제안했다. 유병국, 김순영(2023)에서는 영화개봉 일주일 전을 기준으로 영화 리뷰 데이터를 수집하고 Lasso 회귀 분류 모델을 제안하였으며 회귀계수를 통해 리뷰를 구성하는 단어 중 영화 흥행에 긍부정 영향력 있는 단어를 분석했다.

2.2 앙상블 및 모델 결합 기반 예측 방법론

기존 선행연구에서는 Stacking Ensemble, Blending

Ensemble, AutoML을 활용한 연구들이 수행되었으며 Ahmed *et al.*(2020)은 영화감독 스코어, 영화감독 경험, 영화감독 평점, 배우 스코어 등 총 18개 변수 활용하고 SVM, GBM(Gradient Boosting Machine), XGBoost, Random Forest 등을 활용하여 Voting 모델을 제안했다. Liao *et al.*(2022)은 입소문 데이터나 소셜 플랫폼과 같은 영화 동적 데이터를 사용하지 않고 영화 자체의 특성과 관련된 정적 데이터를 활용하였으며 베이스 모델로 XGBoost, Random Forest, LightGBM을 활용하고 KNN(K-Nearest Neighbors) 모델을 메타 모델로 Stacking Ensemble한 Stacking Fusion Model을 모델 제안을 제안했다.

2.3 RFECV 및 AutoML 방법론

이상거래탐지(Fraud Detection) 및 당뇨병 환자 구분 등 금융, 의학을 비롯한 다양한 도메인에서 머신러닝 기반의 분류 모델에 대한 성능 개선과 학습 시간 단축을 위하여 RFCCV(Recursive Feature Elimination with Cross-Validation)를 통해 적절한 변수를 선택하여 머신러닝 모델을 구축한 연구들이 진행되었다. RFECV는 재귀적 특성 제거를 사용하여 특성을 순위화하고 K-fold 교차 검증(K-fold Cross-Validation)을 통해 최적의 속성을 선별하는 방식이다(Mathew, 2019). Misra and Arun (2020)은 당뇨병 환자를 분류하는데 있어 LR-RFECV (Logistic-Regression REFCV)를 통해 주요한 변수를 선별하고 Logistic Regression, ANN, 나이브 베이지안, SVM, 의사결정 나무 모델을 활용하여 기존 선행연구에 비하여 높은 정확도를 보이는 당뇨병 환자 분류 모델을 제안했다. Mustaqim *et al.*(2021) 은 신용카드 거래에서 이상거래탐지를 위하여 RFECV를 통해 변수를 선택하고 나이브 베이지안, 의사결정 나무 모델을 활용하였으며 K 값이 증가할 수록 선택되어지는 변수가 작아지는 경향을 발견함과 동시에 분류 모델의 학습 속도를 개선시켰다. AutoML은 머신러닝 모델에 대한 깊은 지식이 없이도 다양한 도메인에서 뛰어난 예측 성능을 가진 머신러닝 모델을 구축 할 수 있으며 Paladino *et al.*(2023)은 심장병 진단 예측 모델을 구축하기 위하여 탐색적 데이터 분석(EDA), 데이터 전처리, 특성 공학 등의 머신러닝 모델 개발에 대한 표준 절차를 따라 10개의 머신러닝 모델을 구축하였으나 심장병을 진단하는데 있어 개별 모델보다 AutoML을 통해 구축한 모델이 더 좋은 성능을 보여줬다. Leem *et al.*(2023)은 영화 흥행 예측을 위하여 AutoML에서 지원하는 클러스터링 모델을 통해 최적의 군집 4개를 생성하고 각 군집에 대한 점 추정 회귀 모델을 제안하였으며 SHAP Values를 통해 영화 흥행 예측 결과에 미치는 변수에 대한 긍부정 영향을 분석했다.

〈표 1〉 선행 연구 조사

저자	방식	내용
Liao *et al.*. (2022)	ML 모델을 스태킹 앙상블한 흥행 예측 모델 제안	영화 개봉 후 입소문 데이터나 소셜 플랫폼의 데이터를 사용하지 않고 영화 자체의 특성 자체와 관련된 데이터만을 활용하였으며 XGBoost, Random Forest, LightGBM를 베이스 모델, K-NN을 메타 모델로 박스 오피스 수익 예측을 위한 Stacking Fusion model을 제안 하였음.
Ahmed *et al.* (2020)	머신러닝 모델을 Voting 하여 흥행 예측 모델 제안	영화감독 스코어, 영화감독 평점, 배우 스코어 등 18개 변수를 활용하고 SVM(Support Vector Machine), GBM(Gradient Boosting Machine), XGBoost, Random Forest 를 Voting한 모델을 제안 하였음.
Leem *et al.* (2023)	AutoML 기반 객관적인 모델 선택 및 관객수 예측 모델 제안	AutoML 기반으로 실루엣, 칼린스키-하라바즈, 데이비스-볼딘 지표를 사용해 최적의 군집모델을 선택하고, 각 군집에 대한 회귀 모델을 구축하여 관객수 예측 모델을 제안하였으며, 군집별 SHAP Values를 통해 예측 결과에 긍부정 영향력을 미치는 변수를 분석하였음.

〈표 1〉 선행 연구 조사(계속)

저자	방식	내용
Byun *et al.* (2020)	다변량 시계열 데이터 및 주요 변수 선택 방법을 통한 예측 모델 제안	다변량 시계열 데이터를 활용하여 Random Forest 모델을 통해 주요 변수를 선별하고 잔차 네트워크(Residual Network) 모델을 통해 예측 정확도 약 93%의 흥행 예측 모델을 제안하였음.
Song(2022)	전문가 서베이 정보를 반영한 흥핸 예측 모델 제안	영화 흥행에 영향이 있는 독립변수를 찾아내기 위해서 AHP 기법을 통해 영화 전문가들을 대상으로 설문조사를 진행하였으며 전문가 서베이 정보와 빅데이터를 모두 반영한 영화 흥행 예측 모델을 제안하였음.
Wang *et al.* (2022)	인간의 사전 지식을 머신러닝에 결합한 흥행 예측 모델 제안	박스 오피스 예측에 큰 영향을 주는 변수를 의사결정나무를 통해 71개 도출하였으며, ANN 모델을 통해 학습한 영화 흥행 예측 모델 제안. 실험 결과, 선형 회귀(64.45%), 의사결정나무(71.81%), SVM(72.68%) 보다 높은 성능(79.93%)을 보였음.
Kwon *et al.* (2017)	회귀분석으로 주요 변인 탐색 후 인공신경망과 의사결정 나무를 통한 흥행 예측 모델 제안	회귀분석으로 유의미한 변인을 추출하여 인공신경망과 의사결정나무 모델을 통해 학습한 모델 제안. 전체 변인으로 학습하였을 때 인공신경망이 더 높은 성능을 보였으나 선정된 주요 변인에 따라 학습하였을 때 의사결정나무의 예측력이 더 높았음.
유병국, 김순영 (2023)	영화 배급 전 영화 리뷰를 LASSO 모델을 통해 영향력 있는 단어를 분석	영화개봉 일주일 전을 기준으로 영화 리뷰 데이터를 수집하고 Lasso 모델을 통하여 각 리뷰를 흥행성적에 따라 흥행/비흥행으로 분류 하는 이진 분류 모델 제안. Lasso 회귀계수를 통해 리뷰를 구성하는 단어 중 영화 흥행에 긍부정 영향력을 주는 단어를 분석하였음.
Chang(2017)	정적변수와 동적변수를 조합하여 나이브 베이지안 모델과 신경망 모델을 통해 영화 흥행 예측 모델 제안	감독/배우 평균 관객수와 같은 정적 데이터와 뉴스 기사 수, 블로그 수, 영화평 수와 같은 동적변수(단, 개봉 1주일 이전에 생성된 데이터)를 통해 나이브 베이지안 모델과 인공신경망 모델을 각각 학습. 정적데이터와 동적데이터를 독립적으로 활용하는 것 보다 적절하게 두 가지 데이터를 조합한 인공신경망이 더 좋은 성능을 보였음.
Song(2018)	정적변수와 동적변수를 조합하여 5가지 머신러닝 기반 영화 흥행 예측 모델 제안.	Chang(2017)과 유사하게 정적변수와 동적변수를 활용하였으며 나이브 베이지안, MLP, SVM, Random Forest 모델을 활용하여 독립적으로 개봉 당일, 1주, 2주, 3주까지의 누적 관객수를 예측하는 모델을 제안함. 실험 결과 Random Forest가 가장 좋은 성능을 보였음.
Misra and Arun (2019)	LR-RFECV를 활용하여 주요 변수 선별, 머신러닝 모델을 통해 당뇨병 분류 모델 제안	당뇨병 구분에 활용되는 변수들 중에서 LR-RFECV를 활용하여 주요한 변수를 선별하였으며 Logistic Regression, 인공신경망, 나이브 베이지안, SVM, 의사결정나무 모델을 통해 기존 선행연구 보다 더 높은 성능을 보이는 당뇨병 구분 모델을 제안하였음.
Mustaqim *et al.* (2021)	RFECV를 활용하여 변수를 선택하고 머신러닝 모델을 통해 이상거래탐지 모델 제안	신용카드 거래에서 이상거래탐지를 위해 RFECV를 활용하여 중요 변수를 선택하고 나이브 베이지안, 의사결정나무를 통해 이상거래탐지 모델 제안. K 값이 증가할 수록 선택되어지는 중요 변수의 수가 작아지는 경향을 발견함과 동시에 학습 속도를 개선하였음.
Paladino *et al.* (2023)	AutoML 모델을 활용한 심장병 진단 예측 모델 제안	심장병 진단 예측 모델을 구축하기 위하여 머신러닝 모델 표준 개발 절차에 따라 10개의 머신러닝 모델을 구축하였으나 Pycaret 등 AutoML 모델이 심장병을 진단하는 모델을 만드는 데 있어 개별 모델보다 더 좋은 성능을 보여주는 것을 확인하였음.

Ⅲ. 제안 모델

3.1 개략도

제안하는 방법의 개략도는 <그림 1>과 같다. 특성 공학(Feature Engineering) 단계에서 배우, 감독, 배급사와 장르의 관객수 기술통계 값에 대한 상호작용(Interaction) 파생변수를 생성한다. 변수 선택(Feature Selection) 단계에서 RFECV기법을 통해 상대적으로 중요한 학습 변수만을 선택하고

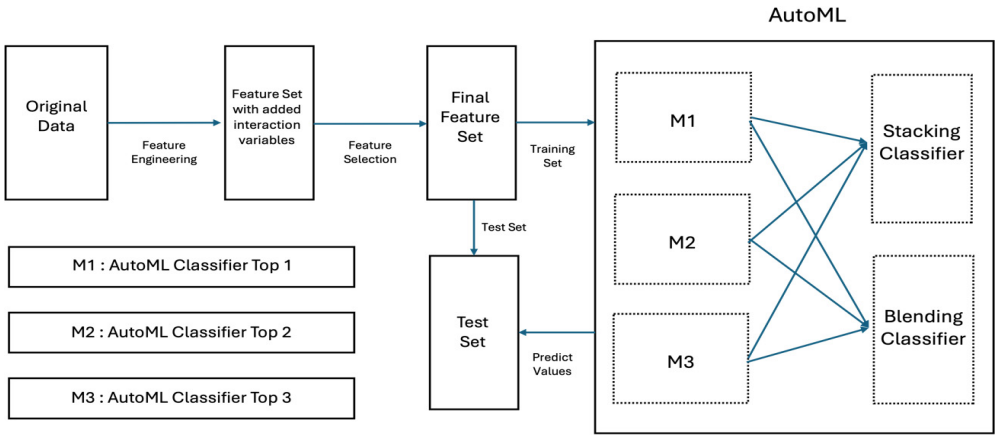

〈그림 1〉 최종 제안모델 개략도

AutoML 모델을 통해 가장 좋은 성능을 보이는 모델 Top3를 선별하고 또한 스태킹, 블렌딩 기법을 통해 앙상블 모델 생성하였다.

3.2 데이터 수집 및 전처리

본 연구에서는 영화 개봉 전후로 변경이 없는 배우, 감독, 배급사 정보와 같은 정적 데이터만을 활용해 흥행 예측 모델을 학습하였으며 개봉 이후 흥행 성적에 따라 유동적으로 변화할 수 있는 인스타그램, X를 비롯한 소셜 데이터, 블로그 게시물 수, 영화 기사 수, 영화 평점 데이터 등 동적 데이터는 배제하였다. 이는 현업에서 영화 개봉 이전에 예측된 흥행 성적에 따라 영화 상영관마다 좌석 비중, 상영 스케줄을 사전에 설정해야 하는 실무적 단계상 영화 개봉 이후 활용할 수 있는 동적 데이터를 반영한 모델은 실무적으로 맞지 않기 때문이다.

KOBIS(영화관 입장권 통합전산망)에서 기간별 필터링 기능을 활용하여 2013년 1월 부터 2024년 10월까지 데이터를 수집하였다. 이때, 연말 시즌에 개봉하여 내년 초까지 상영하는 '노량: 죽음의 바다'와 같은 경우를 고려하여 영화명과 개봉일을 기준으로 관객수를 집계하였다. 본 연구에서는 선행연구에 따라 흥행 영화를 700만, 1,000만 이상의 관객수를 기록한 영화로 선정하였다(Kwon *et al.*, 2017; Song, 2020). 또한, 흥행 기준에 미치지 못하고 대부분의 비중을 차지하는 관객수 100만 명 미만의 영화를 비흥행 영화로 정의하였으며 흥행한 영화에 비하여 비흥행한 영화 비중이 압도적으로 높아 비흥행 클래스로 머신러닝 모델이 오버피팅(Overfitting) 되는 경우를 최소화하기 위하여 당해년도 상위 85% 영화만을 추출하여 흥행 예측 모델 대상 영화로 선별하였다.

Liao *et al.*(2022)의 연구에서 영화 흥행 예측 모델에 학습된 변수인 배우, 감독에 대한 평균 관객수, 누적 관객 수, 출연/연출한 영화의 개수를 학습 변수로 활용한 연구 바탕으로 본 연구에서는 KOBIS에서 활용할 수 있는 정적 데이터인 배우, 감독, 장르, 제작국가, 배급사 데이터를 활용하였다. 또한, 개봉연도를 기준으로 전년도까지 배우 3명, 감독 1명, 배급사와 장르에 대한 관객수 기술통계 값을 학습 변수로 활용하였다. 이때, 활용한 기술통계 값은 동원한 관객수 평균(Mean), 최대 관객수(Max), 누적 관객수(Cumulative Sum), 출연/연출 영화 수(Count)를 활용하였으며 최소(Min)값을 학습에 반영할 경우 성능이 저하되어 해당 변수는 모델 학습에 제외하였다.

영화마다 복수의 장르와 제작국가가 있어 영화 관람 등급, 계절, 제작국가, 장르 변수는 원 핫 인

코딩(One-Hot-Encoding)을 통해 전처리하여 학습하였다. 코로나 기간 여부는 Leem *et al.*(2023) 연구에 따라 본 연구에서도 2020년 1월부터 2022년 2월까지 팬데믹(pandemic) 기간으로 판단하고 해당 기간 개봉한 여부를 원 핫 인코딩을 통해 <표 2> 처럼 학습변수에 포함하였다.

〈표 2〉 흥행예측 학습변수

Category	Description
배우 3명 (기술통계)	배우1_MAX, 배우1_MEAN, 배우1_SUM, 배우1_COUNT, 배우2_MAX, 배우2_MEAN, 배우2_SUM, 배우2_COUNT, 배우3_MAX, 배우3_MEAN, 배우3_SUM, 배우3_COUNT
감독 1명 (기술통계)	감독1_MAX, 감독1_MEAN, 감독1_SUM, 감독1_COUNT
배급사_대표장르 (기술통계)	배급사_대표장르_MAX, 배급사_대표장르_MEAN, 배급사_대표장르_SUM, 배급사_ 대표장르_COUNT
영화장르 (One-Hot-Encoding)	장르_SF, 장르_가족, 장르_공연, 장르_공포(호러), 장르_기타, 장르_다큐멘터리, 장르_드라마, 장르_로맨스, 장르_멜로, 장르_뮤지컬, 장르_미스터리, 장르_범죄, 장르_사극, 장르_서부극, 장르_스릴러, 장르_애니메이션, 장르_액션, 장르_어드벤처, 장르_전쟁, 장르_코미디, 장르_판타지
제작국가 (One-Hot-Encoding)	국가_대만, 국가_독일, 국가_러시아, 국가_미국, 국가_벨기에, 국가_스웨덴, 국가_스페인, 국가_아일랜드, 국가_영국, 국가_인도, 국가_일본, 국가_중국, 국가_프랑스, 국가_한국, 국가_헝가리
계절 (One-Hot-Encoding)	계절_봄, 계절_여름, 계절_가을, 계절_겨울
코로나 기간 여부 (One-Hot-Encoding)	코로나_T, 코로나_F
네이버 검색어 트렌드	Naver_T-28, Naver_T-27, Naver_T-26, Naver_T-25, Naver_T-24, Naver_T-23, Naver_T-22, Naver_T-21, Naver_T-20, Naver_T-19, Naver_T-18, Naver_T-17, Naver_T-16, Naver_T-15, Naver_T-14, Naver_T-13, Naver_T-12, Naver_T-11, Naver_T-10, Naver_T-9, Naver_T-8, Naver_T-7
상호작용 파생변수 (Polynomial Features)	배우1_max*배우1_mean, 배우1_max*배우1_sum, 배우1_max*배우1_count, 배우1_max*배우2_max, 배우1_max*배우2_mean, 배우1_max*배우2_sum, 배우1_max*배우2_count, 배우1_max*배우3_max, 배우1_max*배우3_mean, 배우1_max*배우3_sum, 배우1_max*배우3_count, 배우1_max*감독1_max, 배우1_max*감독1_mean, 배우1_max*감독1_sum, 배우1_max*감독1_count, 배우1_max*배급사_장르_max, 배우1_max*배급사_장르_mean, 배우1_max*배급사_장르_sum, 배우1_max*배급사_장르_count, ... 후략

네이버 개발자 API를 활용하여 개봉일 기준으로 1주일~3주일 전 “영화” 키워드 와 “영화명, 배우1~3명, 감독1명”를 검색하여 상대적 트렌드 비중을 <표 2>처럼 네이버 검색어 트렌드 변수로 영화 흥행 예측 모델에 반영하였다. 이는 흥행/비흥행 영화의 검색 트렌드 패턴을 흥행 예측 모델에 반영하고자 하였다. 네이버 검색어 트렌드는 현 시점 정책상 2016년 1월 부터 데이터를 조회할 수 있어 2016년~2022년까지 개봉한 영화를 <표 4>처럼 학습 데이터셋으로 활용하고 2023년~

2024(10월)년 개봉한 영화를 테스트 셋으로 <표 5>처럼 구성하였다.

Byun *et al.*(2020) 선행연구에서 다중 클래스의 경우 1,000만 이상의 관객수를 기록한 영화를 최고로 흥행한 영화기준으로 두고 100만 단위로 구분하여 각 비중에 따라 1000만 이상, 700~1000만, 500~700만, 300만~500만, 0~300만으로 총 5가지 클래스로 구분하였다. 본 연구에서도 학습 데이터 셋에 해당하는 2016년~2022년까지 개봉한 영화를 대상으로 관객수 100만 단위 누적 비중을 <표 3>처럼 집계였으며 0~100만 비흥행 F클래스(50.10%), 100만~300만을 E클래스(81.96%), 300만~400만(87.58%) D클래스, 400만~700만(94.39%) C클래스, 선행연구 기준으로 흥행에 속하는 700만~1,000만(97.6%), 1,000만 이상(100%)을 각각 B, A 클래스로 구분하였다.

〈표 3〉 관객수 Class 구분 기준

관객수	Cumulative Sum(prop.)	Class
1000만 이상	100.00%	A
900만~1000만	97.60%	B
800만~900만	96.99%	
700만~800만	96.19%	
600만~700만	94.39%	C
500만~600만	93.19%	
400만~500만	90.18%	
300만~400만	87.58%	D
200만~300만	81.96%	E
100만~200만	70.34%	
0~100만	50.10%	F

〈표 4〉 TrainSet 카운트/비중(2016년~2022년)

Class	Count	Prop.
A(1,000만+)	12	2.40%
B(700만~1000만)	16	3.21%
C(400만~700만)	34	6.81%
D(300만~400만)	28	5.61%
E(100만~300만)	159	31.86%
F(0~100만)	250	50.10%
Total	499	100%

〈표 5〉 TestSet 카운트/비중(2023년~2024년(10월))

Class	Count	Prop.
A(1,000만+)	4	4.21%
B(700만~1000만)	2	2.11%
C(400만~700만)	6	6.32%
D(300만~400만)	3	3.16%
E(100만~300만)	25	26.32%
F(0~100만)	55	57.89%
Total	95	100%

3.3 모델링 단계

기존 영화 흥행 예측에 대한 선행 연구에서 영화의 평점, SNS 반응, 영화 개봉 후 1~3주 동안 동원한 관객수, 상영 스크린 수와 같이 동적 데이터와 정적 데이터를 학습에 반영하여 높은 정확도를 보여주는 연구가 진행되었다(Byun *et al.*, 2020; Jeong and Daiki, 2020; Song, 2018). 그러나 현업에서 영화 개봉 이전에 예측된 흥행 성적에 따라 영화 상영관마다 좌석 비중, 상영 스케줄을 사전에 설정해야 하는 실무 단계에서 해당 데이터를 반영한 모델들은 활용하기 어려운 한계점을 가지고 있다.

한정된 정적 데이터를 통해 배우, 감독, 배급사, 장르에 대한 기술 통계 값을 상호작용(Interaction)하여 파생변수를 생성하고 흥행 예측 모델을 개선한 연구는 부족하였다. 이에 따라, 정적 데이터를 통해 Scikit-learn 라이브러리에서 제공하는 PolynomialFeatures 함수를 활용하여 제곱항과 상수항은 생성하지 않고 각 항을 곱하는 방식으로 <표 2>처럼 상호작용 파생 변수를 생성하였다. 해당 기법을 통해 '배우1 평균 관객수 * 감독1 평균 관객 수,' '배우2 평균 관객수 * 배급사_대표장르 평균 관객수'와 같이 흥행 예측 성능을 제고시킬 가능성 있는 상호작용 파생 변수를 생성하였다.

배우, 감독, 배급사, 장르별 상호작용 파생변수를 생성할 경우 조합(Combination)만큼 변수가 생성되며 이때 생성된 파생 변수를 모두 활용하여 학습할 경우 파생변수들이 폭발적으로 증가하게

되어 모델의 복잡성이 증가하고 오히려 성능이 감소하거나 모델 학습시간이 증가할 수 있다. 이에 따라 다양한 도메인에서 RFECV 기법을 활용하여 변수 선택을 수행한 연구를 토대로 본 연구에서는 Decision Tree 모델을 기준으로 영향력이 낮은 변수를 10-fold 교차검증(Cross-Validation)을 통해 재귀적으로 제거해 나가는 방식으로 적절한 변수를 자동으로 선택하였다. 결과적으로, 본 연구에서는 배우3명, 감독1명, 배급사_장르의 기술 통계 변수 20개를 통해 190개의 파생변수를 생성하였으며 RFECV를 통해 210개 변수 중 주요변수 37개를 <표 6> 처럼 추출하여 학습하였고 원 핫 인 코딩된 장르, 등급, 코로나 기간 변수와 네이버 트렌드 데이터를 반영하여 흥행 예측 모델을 학습하였다.

〈표 6〉 RFECV를 통하여 추출한 변수/상호작용 파생변수

Category	추출변수 컬럼명
기존변수 (6가지)	actor_top2_max, actor_top2_mean, actor_top3_mean, top1_배급사_장르_mean, top1_배급사_장르_sum, top1_배급사_장르_count
파생변수 (31가지)	actor_top1_max*actor_top1_sum, actor_top1_mean*actor_top1_sum, actor_top1_mean*actor_top3_sum, actor_top1_mean*top1_배급사_장르_max, actor_top1_mean*top1_배급사_장르_sum, actor_top1_mean*director_top1_sum, actor_top1_sum*actor_top1_count, actor_top1_sum*actor_top2_count, actor_top1_sum*actor_top3_mean, actor_top1_sum*director_top1_mean, actor_top1_count*actor_top2_mean, actor_top1_count*actor_top3_max, actor_top1_count*top1_배급사_장르_mean, actor_top1_count*top1_배급사_장르_count, actor_top2_max*top1_배급사_장르_sum, actor_top2_mean*actor_top3_sum, actor_top2_mean*top1_배급사_장르_mean, actor_top2_mean*director_top1_sum, actor_top2_sum*actor_top3_count, actor_top2_sum*director_top1_count, actor_top2_count*top1_배급사_장르_mean, actor_top3_mean*top1_배급사_장르_mean, actor_top3_mean*top1_배급사_장르_sum, actor_top3_count*top1_배급사_장르_max, actor_top3_count*top1_배급사_장르_sum, top1_배급사_장르_max* top1_배급사_장르_mean, top1_배급사_장르_mean*director_top1_sum, top1_배급사_장르_sum*director_top1_count, top1_배급사_장르_count*director_top1_count, director_top1_max*director_top1_sum, director_top1_max*director_top1_count

〈표 7〉 AutoML(Pycaret) 파라미터

Parameter	Value
Target type	Multiclass
Original data shape	(499, 83)
Transformed data shape	(499, 83)
Transformed train set shape	(349, 83)
Transformed test set shape	(150, 83)
Numeric features	82
Preprocess	TRUE
Imputation type	simple
Numeric imputation	mean
Categorical imputation	mode
Fold Generator	StratifiedKFold
Fold Number	10
CPU Jobs	-1
Use GPU	FALSE
Log Experiment	FALSE

데이터셋의 구조에 따라 최적의 모델이 다를 수 있으며 연구자의 개인적인 판단을 최소화하기 위함과 동시에 머신러닝에 대한 깊은 지식이 없이도 뛰어난 예측 성능을 가지는 모델을 만들 수 있는 AutoML을 통해 흥행 예측 모델을 생성하였다 (Leem *et al.*, 2023; Paladino *et al.*, 2023). 이때

AutoML 라이브러리로 PyCaret을 활용하였으며 파라미터의 설정은 <표 5>와 같다. 학습과정 중 Stratified-10-fold를 통해 검증결과 성능이 가장 좋은 모델 Top3를 선별하였으며 Top3 모델을 Stacking, Blending하여 앙상블 모델 또한 생성하였다.

Ⅳ. 실험 및 결과

4.1 베이스라인 모델

베이스라인 모델은 Liao *et al.*(2022)가 제안한모델로 선정하였으며 모델 구조는 <그림 2>와 같다. 해당 모델은 영화 제작 초기 단계에서 박스 오피스 수익을 예측하는 모델이며 영화 자체의 특성에 관한 데이터를 기반으로 SNS 플랫폼의 입소문 데이터 없이 흥행을 예측한 모델이다. XGBoost, LightGBM, Random Forest을 베이스 모델, KNN 모델을 메타 모델로 Stacking Ensemble한 모델로 높은 정확도를 보여준 모델이며 국외 영화 흥행 예측 모델에 대한 선행 연구에서도 벤치마킹 모델로 활용되었다(Madongo *et al.*, 2024).

4.2 평가 척도

기존 국내외 선행 연구들은 정확도(Accuracy), 정밀도(Precision), 민감도(Recall), F1-Score(Weighted)를 평가 척도로 모델의 성능을 검증하거나 AHPR (Average Percentage Hit Rate)과 AHPR에서 파생된 AHPR-Bingo, AHPR-1-Away 활용하여 흥행예측 모델의 성능을 검증하였다(Ahmed *et al.*, 2020; Liao *et al.*, 2022). 그러나 해당 평가 척도만을 활용하여 모델 성능을 평가할 경우 테스트 데이터에서 비교적 비중이 높은 비흥행 영화를 잘 맞춘 것인지 또는 비교적 비중이 낮은 흥행영화를 잘 맞춘 것인지 명확히 구분되지 못하는 한계점을 가지고 있다. 이에 따라 본 연구의 평가척도는 F1-Macro를 통해 제안 모델이 불균형한 모든 클래스에서 평균적으로 정답을 잘 맞힌 것인지를 기준으로 제안 모델 성능을 검증하였다. 또한 AHPR-Bingo, AHPR-1-Away를 활용하여 절대적, 상대적 척도로 제안 모델의 성능을 판단하였다.

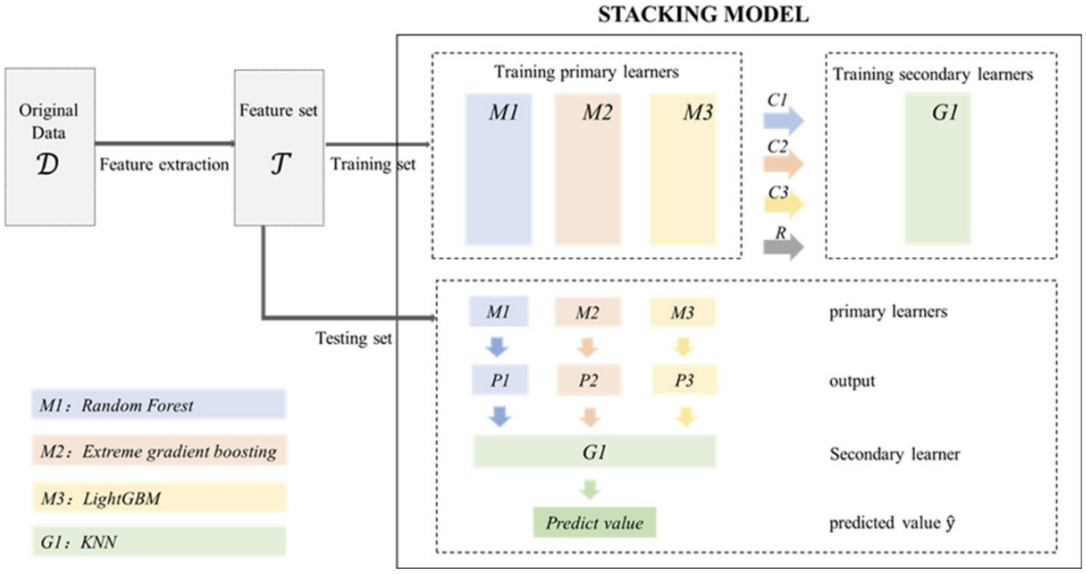

〈그림 2〉 Stacking Fusion Model, Liao *et al.*(2022)

4.3 실험 및 결과

<표 8>과 같이 연구모델(1)은 베이스라인 모델과 동일한 데이터로 AutoML 모델을 활용하여 성능을 테스트하였다. 연구모델(2)는 Polynomial Features를 통해 배우, 감독, 배급사, 장르에 대한 파생변수를 생성하여 별도의 전처리 없이 학습한 모델이다. 최종 제안모델은 Decision Tree 모델을 기반으로 RFECV를 통해 영향력이 비교적 낮은 상호작용 파생변수를 제외하여 학습한 모델이다. 각 단계에서 F1-macro 기준 가장 좋은 성능을 보여주는 모델을 볼드(bold) 표시하였다.

결과적으로 연구모델(1)은 베이스라인 모델과 비교하였을 때 Top3 모델 중 Extra Trees 모델이 Random Forest 모델 보다 더 나은 성능을 보여줬으며 이는 특정 모델을 고정하여 예측 모델을 학습시키는 것 보다 데이터 셋에 맞게 AutoML를 통한 학습이 더 나은 결과를 보여 줄 수 있음을 확인하였다. 또한 베이스라인 모델은 단일 모델의 성능이 Stacking Ensemble한 모델 보다 성능이 더 좋았으며 이는 <표 9>처럼 학습 과정 데이터셋 특성상 비중이 높은 비흥행 영화에 오버피팅 되어 성능이 낮게 평가된 것으로 확인되었다.

연구모델(2)는 기존 변수 20개와 상호작용 파생변수 190개 총 210개를 전처리 없이 모두 추가한 모델로 베이스라인 모델과 연구모델(1)에 비하여 LightGBM 모델과 Blending 한 모델이 더 좋은 성능을 보여주는 것으로 확인되었다. 이는 영화 배우, 감독, 배급사, 장르 등 주요변수들에 대한 상호작용 파생변수를 학습에 추가하는 것이 흥행 예측 모델의 성능을 개선시킬 수 있는 한 가지 방안으로 활용될 가능성을 보여준다. 최종 제안모델은 RFECV를 통해 20개 기술 통계 변수와 상호작용 파생변수 190개로 총 210개 변수 중 37개의 변수를 자동으로 선택하여 학습하였으며 실험결과 XGBoost 모델이 베이스라인, 연구모델(1), 연구모

〈표 8〉 최종 제안모델 성능평가 표

구분	모델	AHPR-Bingo	AHPR-1-Away	**F1-Macro**
BaseLine (Liao *et al.* 2022)	**Extreme Gradient Boosting**	42.11%	81.05%	33.38%
	Light Gradient Boosting Machine	47.37%	87.37%	31.59%
	Random Forest Classifier	41.05%	86.32%	15.04%
	Stacking Ensemble	43.16%	81.05%	14.94%
연구모델(1) (AutoML)	Extreme Gradient Boosting	42.11%	81.05%	33.38%
	Light Gradient Boosting Machine	47.37%	87.37%	31.59%
	Extra Trees Classifier	46.32%	84.21%	17.21%
	Stacking Ensemble	45.26%	87.37%	16.42%
	Blending Ensemble	46.32%	84.21%	**34.89%**
연구모델(2) (AutoML+ Interaction Features)	Light Gradient Boosting Machine	46.32%	86.32%	34.54%
	Extreme Gradient Boosting	40.00%	81.05%	29.99%
	Extra Trees Classifier	40.00%	83.16%	16.94%
	Stacking Ensemble	43.16%	86.32%	15.87%
	Blending Ensemble	46.32%	87.37%	**36.30%**
최종 제안모델 (AutoML+Interaction Features+RFECV with Decision Tree)	**Extreme Gradient Boosting**	43.16%	84.21%	**48.54%**
	Light Gradient Boosting Machine	47.37%	85.26%	33.38%
	Extra Trees Classifier	40.00%	86.32%	19.16%
	Stacking Ensemble	45.26%	87.37%	16.32%
	Blending Ensemble	47.37%	85.26%	36.12%

〈표 9〉 2023년~2024년(10월) 영화흥행 Top15위 비교

구분	BaseLine-Stacking Fusion Model		Proposed Model-XGBoost Model	
영화명	예측	실제	예측	실제
파묘	5	0	0	0
범죄도시4	5	0	4	0
범죄도시3	5	0	0	0
서울의 봄	4	0	0	0
인사이드 아웃 2	4	1	1	1
베테랑2(24.10까지)	4	1	2	1
파일럿	4	2	1	2
미션 임파서블: 데드 레코닝 PART ONE	5	2	5	2
가디언즈 오브 갤럭시: Volume 3	5	2	2	2
노량: 죽음의 바다	5	2	2	2
밀수	5	2	2	2
스즈메의 문단속	5	2	4	2
콘크리트 유토피아	5	3	3	3
오펜하이머	0	3	3	3
웡카	4	3	4	3

※ A Class : 0 / B Class : 1 / C Class : 2 / D Class : 3 / E Class : 4 / F Class : 5

델(2)에서 제안한 모델보다 더 좋은 성능을 보여주는 것을 확인하였다. 이는 학습 변수에 비하여 상대적으로 학습량이 부족한 학습 데이터 특성상 모든 상호작용 파생변수를 활용하여 학습시키는 것 보다 학습 중요도가 상대적으로 중요한 변수를 선별하여 학습하는 것이 더 나은 성능을 보여주는 것으로 확인되었다. 또한 베이스라인 모델과 최종 제안모델을 통해 2023년~2024년(10월) 사이 개봉한 영화 중 가장 흥행한 Top 15위 영화를 예측한 결과 베이스라인 모델은 오버피팅 되어 모두 오답으로 예측되었지만 최종 제안 모델은 <표 9> 처럼 60%의 정확도를 보여주었다.

4.4 학습 변수 중요도

<그림 3>을 토대로 최종 제안모델에서 학습 변수들에 대한 중요도를 보았을 때 장르 구분, 펜데믹 여부, 네이버 트렌드 변수가 모델에 주요한 변수로 작용하였다. 또한 본 논문에서 제안한 상호

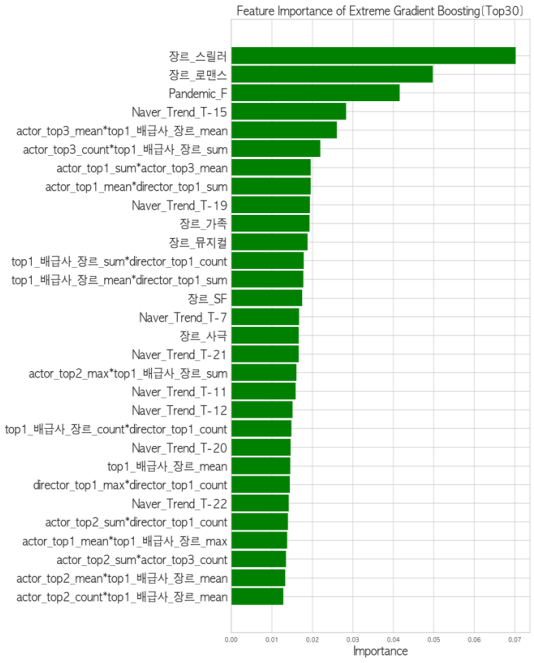

〈그림 3〉 최종 제안모델(XGBoost)변수 중요도 Top 30위

작용 파생변수 즉, 배우3명, 감독1명, 배급사와 장르별 관객수에 대한 기술 통계 값의 파생 변수들이 학습에 중요한 역할을 미치는 것을 확인할 수 있었다. 특히, 배급사 장르별 파생변수들이 해당 모델에서 주요한 영향을 미치는 것을 확인할 수 있었으며 '배급사 장르별 평균 관객수/누적 관객수'와 '배우3의 평균 관객수' / '배우3의 작품 수'/ '감독의 작품 수' / '감독의 누적 관객수' 등이 학습에 주요한 변수임을 판별할 수 있었으며 또한 '배우1'의 누적 관객수/평균값의 파생변수, '감독'의 누적 관객수/작품의 수가 학습에 주요한 영향을 미치는 변수임을 확인할 수 있었다.

Ⅴ. 결 론

본 연구는 영화 정적 데이터를 활용하여 AI 및 기계 학습(Machine Learning, ML) 기반의 영화 흥행 예측 모델을 개발하고, 이를 기존 통계적 방법 및 베이스라인 모델과 비교하여 성능을 평가하였다. 기존 연구들이 정적 데이터와 동적 데이터를 혼합하여 흥행 예측 모델을 제안한 것과 달리, 본 연구는 영화 정적 데이터에만 초점을 맞추어 실질적으로 활용 가능한 예측 모델을 구축하였다.

5.1 실무적 시사점 및 학술적 기여

연구 결과, AutoML을 활용한 연구모델(1)은 베이스라인 모델에 비해 더 나은 예측 성능을 보였으며, 이는 데이터 셋에 적합한 모델을 자동으로 선택하는 AutoML의 유효성을 입증하였다. 또한, 연구모델(2)에서 상호작용 파생변수를 추가한 결과, 일부 모델에서 성능이 향상되었으나 변수의 과도한 증가로 인해 모델 복잡성이 높아지며 학습 시간이 증가하는 한계가 나타났다. 이를 개선하기 위해 RFECV(Recursive Feature Elimination with Cross-Validation)를 활용하여 상호작용 파생변수 중 주요 변수만을 선별한 최종 제안모델은 기존 베이스라인 모델 및 연구모델(1)과 (2)를 뛰어넘는 성능을 보였다. 특히, 제안된 상호작용 파생변수(예: 배급사-장르별 평균 관객수 조합)는 모델 성능 개선에 주요한 기여를 한 변수로 나타났다.

이러한 연구 결과는 실무적으로도 다양한 마케팅 전략 및 배급 계획 수립에 기여할 수 있다. 첫째, 배급사는 제안모델에서 도출된 "배급사-장르별 평균 관객수 조합"을 활용하여 특정 장르에서 자사 성과를 극대화할 수 있는 맞춤형 배급 전략을 수립할 수 있다. 둘째, RFECV를 통해 도출된 주요 변수들은 마케팅 자원 배분의 효율성을 높이는 데 활용될 수 있으며, 특정 장르-배급사 조합에 집중적인 마케팅 자원을 투입하는 전략을 통해 예산 낭비를 줄일 수 있다. 셋째, 특정 장르에서 강점을 보이는 배급사들 간 협업 기회를 발굴함으로써 관객층 확대 및 시너지 창출이 가능하다. 넷째, 제안모델은 장르별로 반응이 좋은 관객층을 파악하여 맞춤형 마케팅 캠페인을 설계하고 관객 유입을 극대화하는 데 기여할 수 있다. 마지막으로, 배급사는 모델을 활용하여 잠재적으로 높은 관객 수를 유발할 수 있는 장르 및 배급 전략을 예측함으로써 신규 프로젝트 기획 시 데이터 기반 의사결정을 내릴 수 있다.

최종 제안모델은 2023년~2024년 개봉 영화의 흥행 성과를 예측하는 테스트 데이터셋에서 높은 F1-Macro 성능을 보여주었으며, 흥행 상위 15개 영화 예측에서 베이스라인 모델의 한계를 극복하고 60%의 정확도를 기록하였다. 이는 영화 흥행 예측에서 정적 데이터를 활용한 상호작용 변수를 반영하는 접근법이 실질적으로 유용하며, 데이터 기반 의사결정 과정에서 의미 있는 결과를 도출할 수 있음을 시사한다.

본 연구는 다음과 같은 학술적 기여를 제공한다. 첫째, 정적 데이터를 활용한 기존 연구(Ahmed *et al.*, 2020; Liao *et al.*, 2022)와 유사하게 정적 데이터를 활용한 영화 흥행 예측 모델을 개발하였지만, 기존 연구들이 주로 앙상블 모델(예: 스태킹, 보팅)을 통해 예측 성능을 개선하려는 데 초점을 맞춘 것과 달리, AutoML을 통해 데이터셋에 최적

화된 모델을 자동으로 선택하고 평가하였다. 이는 연구자의 주관적 판단을 최소화하고, 데이터 특성에 맞는 모델을 객관적으로 선택하는 접근법의 유효성을 입증한 점에서 차별화 될 수 있다.

둘째, AutoML을 활용하여 군집별로 최적화된 회귀 모델을 개발한 것(Leem *et al.*, 2023)과 비교하여, 본 연구는 RFECV를 활용하여 상호작용 파생변수 중 주요 변수를 선별하고, 이를 최적화된 AutoML 모델에 적용하였다. 이러한 접근법은 복잡한 변수 공간에서 주요 변수만을 효과적으로 선별함으로써, 모델 성능뿐만 아니라 학습 효율성을 향상시키는 데 기여하였다.

셋째, 도메인별 분류 문제에서 주요 변수 선택 기법으로 RFECV를 활용하여 좋은 성과를 보여주었다(Misra and Arun, 2019; Mustaqim *et al.*, 2021). 본 연구는 이 기법을 영화 흥행 예측 문제에 적용하여, 상호작용 파생변수의 기여도를 정량적으로 평가하고 최적의 변수 조합을 도출한 최초의 시도 중 하나로 평가될 수 있다. 특히, “배급사-장르별 평균 관객수 조합”과 같은 상호작용 파생변수의 효과를 정량적으로 입증한 점은 기존 연구에서 다루지 않은 새로운 연구 방법론이다.

넷째, 기존 연구에서 정적 데이터와 동적 데이터를 결합하여 예측 성능을 높이려는 시도(Chang, 2017; Song, 2018)와 달리, 본 연구는 개봉 전 단계에서 활용 가능한 정적 데이터만으로도 높은 예측 성능을 달성할 수 있음을 보여주었다. 이는 개봉 전 의사결정 단계에서 활용 가능한 데이터 분석 프레임워크를 제시했다는 점에서 실무에 활용할 수 있다.

다섯째, AutoML 활용 사례(Paladino *et al.*, 2023)와 유사하게, 본 연구는 AutoML이 제공하는 표준화된 모델 개발 및 평가 프로세스가 영화 흥행 예측 문제에서도 효과적임을 확인하였다. 특히, 흥행 상위 15개 영화 예측에서 60%의 정확도를 기록한 본 연구의 제안모델은 AutoML 기반 접근법의 실제 적용 가능성을 제시한다.

5.2 한계 및 향후 연구 방향

본 연구는 정적 데이터만을 활용하여 흥행 예측 모델을 구축하였으나, 영화 개봉전 확보 가능한 동적 데이터를 활용하여 예측 성능을 더욱 개선할 가능성이 존재한다. 예를 들어 개봉 전 확보 가능한 시사회 관련 실시간 소셜 미디어 반응, 영화 개봉전 유튜브(YouTube)에 공개된 예고편 영상의 리뷰 감성 분석 같은 동적 요소를 추가로 고려한다면 더욱 정교한 모델 개발이 가능할 것이다. 또한, 데이터셋의 편향성을 줄이기 위해 더 다양한 장르 및 국가의 영화를 포함한 데이터셋으로 확장하는 연구가 필요하다.

결론적으로, 본 연구는 영화 정적 데이터를 활용한 흥행 예측 모델의 새로운 가능성을 제시하였으며, 데이터 기반 의사결정 연구 및 실무적 활용에 기여할 수 있는 기틀을 마련하였다. 향후 연구에서는 본 연구의 한계를 보완하고, 예측 모델을 보다 다양한 산업과 데이터 유형에 적용하는 연구가 이어지길 기대한다.

참 고 문 헌

[1] 김병도, 표태형, “개봉 전 영화의 수요예측모형”, *경영논집*, 제36권, 제1호, 2002, pp. 1-23.

[2] 김병선, “영화 유형에 따른 흥행 예측 요인 비교 연구: 2005～2007년 국내 개봉 영화의 개봉 방식 및 상영 기간에 따른 유형 분류를 중심으로”, *한국언론학보*, 제53권, 제1호, 2009, pp. 257-287.

[3] 송정아, 최근호, 김건우, “영화 흥행에 영향을 미치는 새로운 변수 개발과 이를 이용한 머신러닝 기반의 주간 박스오피스 예측”, *지능정보연구*, 제24권, 제4호, 2018, pp. 67-83.

[4] 영화진흥위원회, “2023년 한국 영화산업 결산 보고서”, KOFIC 연구, 2024.4.9, Available at: https://www.kofic.or.kr/kofic/business/rsch/findPolicyList.do.

[5] 오승은, “주요국의 자국 영화 점유율 현황”, 저작권 기술산업 통계정보 보고서, 2024.7.21, Available at: https://www.copyright.or.kr/information-materials/trend/tmis/view.do?brdctsno=53169.

[6] 유병국, 김순홍, “유통배급단계에서의 영화흥행예측-영화리뷰의 텍스트마이닝을 이용하여”, *한국물류학회지*, 제33권, 제1호, 2023, pp. 95-105.

[7] Ahmed, U., H. Waqas, M. T. Afzal, “Pre-production box-office success quotient forecasting”, *Soft Computing*, Vol.24, No.9, 2020, pp. 6635-6653.

[8] Byun, J. H., J. H. Kim, Y. J. Choi, and H. C. Lee, “Movie box-office prediction using deep learning and feature selection: Focusing on multivariate time series”, *Journal of The Korea Society of Computer and Information*, Vol.25, No.6, 2020, pp. 35-47.

[9] Chang, J. Y., “An experimental evaluation of box office revenue prediction through social bigdata analysis and machine learning”, *The Journal of the Institute of Internet, Broadcasting and Communication*, Vol.17, No.3, 2017, pp. 167-173.

[10] Jeong, C. M. and D. Min, “A study on the performance evaluation of machine learning for predicting the number of movie audiences”, *Journal of Society for e-Business Studies*, Vol.25, No.2, 2020

[11] Kwon, S. H., K. W. Park, and B. H. Chang, “A comparison of predicting movie success between artificial neural network and decision Tree”, *Asia-pacific Journal of Multimedia Services Convergent with Art, Humanities, and Sociology*, Vol.7, No.4, 2017, pp. 593-601.

[12] Leem, S., J. Moon, and S. Rho, “A box office type classification and prediction model based on automated machine learning for maximizing the commercial success of the Korean Film Industry”, *Journal of Platform Technology*, Vol.11, No.3, 2023, pp. 45-55.

[13] Liao, Y., Y. Peng, S. Shi, V. Shi, and X. Yu, “Early box office prediction in China’s film market based on a stacking fusion model”, *Annals of Operations Research*, 2022, pp. 1-18.

[14] Madongo, C. T., Z. Tang, and J. Hassan, “A cross-modal transformer based model for box-office revenue prediction”, *Journal of Advances in Information Technology*, Vol.15, No.7, 2024.

[15] Mathew, T. E., “A logistic regression with recursive feature elimination model for breast cancer diagnosis”, *International Journal on Emerging Technologies*, Vol.10, No.3, 2019, pp. 55-63.

[16] Misra, P. and S. Y. Arun, “Improving the classification accuracy using recursive feature elimination with cross-validation”, *Int. J. Emerg. Technol*, Vol.11, No.3, 2020, pp. 659-665.

[17] Mustaqim, A. Z., S. Adi, Y. Pristyanto, and Y. Astuti, “The effect of recursive feature elimination with cross-validation (RFECV) feature selection algorithm toward classifier performance on credit card fraud detection”, *International Conference on Artificial Intelligence and Computer Science Technology (ICAICST) IEEE*, 2021, pp. 270-275.

[18] Paladino, L. M., A. Hughes, A. Perera, O. Topsakal, and T. C. Akinci, “Evaluating the performance of automated machine learning (AutoML) tools for heart disease diagnosis and prediction”, *AI*, Vol.4, No.4, 2023, pp. 1036-1058.

[19] Song, M. G., “Development of demand prediction model for video contents using digital big data”, *Journal of Industrial Convergence*, Vol.20, No.4, 2022, pp. 31-37.

[20] Wang, D., Y. Wu, C. Gu, Y. Wang, X. Zhu, W. Zhou, and X. M. Lin, “A movie box office revenues prediction algorithm based on human-machine collaboration feature processing”, *Journal of Engineering Research*, 2022.

Information Systems Review
Volume 27 Number 1
February 2025

Predicting Box Office Success Using AI and Machine Learning: A Pre-Release Data-Driven Approach

Hyeon-Geon Kim* · Jihwan Woo**

Abstract

This study proposes a box office prediction model utilizing AI and machine learning (ML) techniques based on static data available before a film's release and evaluates its performance by comparing it with existing baseline models. Using KOBIS data collected from 2013 to 2024, we generated descriptive statistics and interaction-derived variables for actors, directors, distributors, and genres. Key features were selected using Recursive Feature Elimination with Cross-Validation (RFECV). Additionally, an AutoML approach was applied to train an optimized model for the dataset, and Naver search trend data was incorporated to enhance predictive performance. Experimental results demonstrated that the proposed model outperformed both baseline and existing research models, achieving high accuracy based on F1-Macro and AHPR-Bingo evaluation metrics. Notably, interaction-derived variables were identified as key contributors to model performance improvement, confirming that prediction models based on static data can serve as valuable tools in the decision-making processes of the film industry. This study makes both academic and practical contributions by presenting a box office prediction model solely based on static data. The findings provide a useful framework for film producers and distributors to support strategic decision-making before release. Future research can extend this study by incorporating dynamic data and applying the model to diverse datasets for further validation and enhancement.

***Keywords:* Box Office Prediction, Automated Machine Learning, Interaction Data, Recursive Feature Elimination with Cross Validation**

* Data Scientist, CJ OliveNetworks
** Corresponding Author, Adjunct Professor, KAIST Colleage of Business

◐ 저 자 소 개 ◑

김 현 건 (hg.kim32@cj.net)

CJ올리브네트웍스 AI연구소에서 Data Scientist로 재직 중이다. 주요 관심분야는 다양한 산업 현장의 데이터 분석을 통한 비즈니스 인사이트 도출을 진행하는 것이다.

우 지 환 (jihwan.woo@kakao.com)

삼성전자 삼성 리서치, 미국 카네기멜론대학 로봇연구소 등을 거쳐 현재 CJ 올리브네트웍스 AI연구소에 재직 중이며, 고려대학교 기술경영대학원의 겸임교수를 역임하였다. 컴퓨터 비전 기반 로보틱스 및 AI 연구 개발 경력이 있으며, 이와 함께 기술 전략 수립 및 가치 평가 등에 관심이 있다.

논문접수일 : 2024년 12월 06일 **게재확정일 : 2025년 01월 24일**
1차 수정일 : 2025년 01월 07일