

EDA 분석 결과 비교 보고서 (이미지 포함)

분석 대상: eda_visualization.ipynb (10k) vs eda_visualization_60k.ipynb (60k)

1. 데이터셋 요약 및 클래스 비율

두 데이터셋은 보안 로그의 정상/공격 요청 비율을 시각화하여 분석합니다. 데이터의 규모는 다르지만 클래스 간의 비율은 일정하게 유지되고 있습니다.

구분	10k 데이터셋 (Small)	60k 데이터셋 (Large)
전체 데이터 수	10,000 건	61,065 건
정상 (Normal)	5,895 건 (58.95%)	36,000 건 (58.95%)
공격 (Anomalous)	4,105 건 (41.05%)	25,065 건 (41.05%)

2. HTTP 메서드별 공격 비율

HTTP Method(GET, POST, PUT 등)와 라벨 간의 관계를 분석합니다. POST 요청은 주로 데이터 전송에 사용되므로 공격의 주요 통로가 될 수 있습니다.

지표	10k 데이터셋	60k 데이터셋
POST 요청 총계	2,945 건	17,580 건
전체 대비 POST 비율	29.45%	28.79%

 **비교 분석:** 두 파일 모두에서 공격 데이터의 상당수가 POST 메서드에 분포하고 있음을 확인할 수 있으며, 규모가 커져도 메서드 점유율은 유사하게 유지됩니다.

3. 길이 분포 분석 (Length Distribution)

URL 및 Body의 길이 분포를 히스토그램으로 확인한 결과입니다.

- **공통 발견:** 공격 요청(Anomalous)의 URL 길이가 정상 요청보다 평균적으로 더 긴 경향을 보입니다.
- **특이점:** 60k 데이터셋에서는 데이터가 많아짐에 따라 분포의 꼬리(Tail) 부분이 더 길게 나타나며, 매우 긴 URL을 가진 극단적인 공격 사례들이 더 많이 관측됩니다.

4. 키워드 패턴 분석 (Keyword Search)


'SELECT', 'DROP', '<script>' 등 보안 위협 키워드가 포함된 요청을 필터링한 결과입니다.

'select' 키워드 검출	10k 데이터셋	60k 데이터셋
검출된 총 요청 수	37 건	214 건
정상 데이터 내 검출	0 건	2 건
공격 데이터 내 검출	37 건	212 건

 **특이사항:** 60k 데이터셋에서는 'select' 단어가 포함된 정상 요청이 2건 발견되었습니다. 이는 데이터 규모가 커짐에 따라 오탐(False Positive)의 가능성이 있는 실제 데이터의 복잡성이 드러나기 시작했음을 의미합니다.

5. 시각화 비교 화면 (Streamlit Dashboards)

데이터 규모에 따른 EDA 시각화 결과의 일관성과 차이를 한눈에 비교하기 위해, 두 데이터셋에 대한 Streamlit 대시보드 화면을 캡처하여 첨부합니다.



결론 및 제언

- 일관성:** 두 데이터셋은 규모에 관계없이 공격의 유형과 패턴(긴 URL, 특정 키워드 집중)이 일관되게 나타납니다.
- 분석 환경:** 10k 파일은 시각화 라이브러리의 속도가 빨라 빠른 실험에 적합하고, 60k 파일은 희귀한 패턴(정상 요청 내 키워드 포함 등)을 탐색하는 데 유리합니다.
- 추천:** 초기 EDA와 시각화 레이아웃 구성은 10k로 진행하되, 최종 모델 학습 및 패턴 확정은 60k 데이터를 기준으로 수행하는 것이 바람직합니다.

웹 보안 데이터 규모별 EDA 비교 및 분석

본 보고서는 HTTP 요청 로그 데이터를 활용한 두 가지 규모의 데이터셋(10k vs 60k)을 대상으로, Jupyter Notebook에서 수행된 모든 분석 항목을 기반으로 작성되었습니다. 각 분석 항목별 결과와 데이터 규모에 따른 차이점을 상세히 기술합니다.

1. 분석 항목: 정상 vs 공격 비율 (Class Distribution)

전체 데이터셋에서 정상(Normal) 요청과 공격(Anomalous) 요청이 차지하는 비중을 분석한 결과입니다.

구분	10k 데이터 (Small)	60k 데이터 (Large)
전체 건수	10,000건	61,065건
정상 (Normal)	5,895건 (58.95%)	36,000건 (58.95%)
공격 (Anomalous)	4,105건 (41.05%)	25,065건 (41.05%)

분석 결과: 두 데이터셋 모두 약 6:4의 일관된 비율을 유지하고 있어, 데이터 증설 과정에서 원본 데이터의 분포가 잘 보존되었음을 확인하였습니다.

2. 분석 항목: HTTP 메서드별 정상/공격 분포

HTTP Method(GET, POST 등)에 따른 보안 위협의 분포를 분석하였습니다.

- **POST** 요청 빈도: 10k(2,945건) 대비 60k(17,580건)으로 약 6배 증가하였습니다.
- 특이사항: 공격 데이터의 상당수가 POST 메서드 또는 쿼리 파라미터가 복잡한 GET 메서드에 집중되어 있습니다.

3. 분석 항목: URL 및 Body 길이 분석 (Histogram & Box Plot)

URL 길이 히스토그램, URL 길이 Box Plot, POST 본문 길이 분석을 포함한 결과입니다.

지표 (단위: Byte)	10k 데이터 평균	60k 데이터 평균
정상 URL 길이	약 45	약 46

지표 (단위: Byte)	10k 데이터 평균	60k 데이터 평균
공격 URL 길이	약 112	약 115

통계 요약: Box Plot 분석 결과, 공격 데이터의 URL 길이는 정상 데이터보다 훨씬 넓은 범위를 가지며, 60k 데이터셋에서는 1,000자 이상의 극단적인 페이로드를 가진 이상치(Outlier)가 더 빈번하게 관찰됩니다.

4. 분석 항목: 키워드 기반 패턴 분석

공격 카테고리별 키워드 빈도 및 Top 15 키워드를 분석한 상세 결과입니다.

키워드 탐지 상세 표 (공격 빈도순 정렬)

키워드	카테고리	10k (공격 탐지)	60k (공격 탐지)
' (Single Quote)	SQL Injection	높음	매우 높음
select	SQL Injection	37건	212건
<script	XSS	다수	매우 다수

분석 결과: Top 15 키워드 차트에서 SQL Injection 관련 특수문자와 키워드가 압도적인 비중을 차지했습니다. 특히 60k 데이터에서는 'select'가 정상 요청에서 2건 발견되는 등, 실제 운영 환경에서 발생할 수 있는 '정상적인 텍스트 내 키워드 포함' 사례가 포착되었습니다.

5. 분석 항목: EDA 핵심 발견 (Final Findings)

두 노트북의 최종 요약 섹션에서 도출된 핵심 결론입니다.

- 발견 1: 공격 요청의 URL은 평균적으로 정상보다 2배 이상 길며, 이는 탐지 모델의 주요 피처로 활용 가능합니다.
- 발견 2: SQL, XSS, Path Traversal 키워드는 공격 데이터에 압도적으로 집중되어 나타납니다.
- 발견 3: 본 데이터셋은 개별 공격 유형(SQLi 등)에 대한 세부 라벨 없이 이진 분류(정상/공격)로 구성되어 있습니다.
- 발견 4: 텍스트 전처리(Decoding)를 통해 복잡한 인코딩 뒤에 숨겨진 공격 패턴을 직접 확인할 수 있었습니다.